公司知识库文档管理制度

版本 1.0 发布日期 2026年10月22日

POLICY-BEGIN

本制度用于说明公司知识库中文档的提交、索引、检索与维护流程，供内容维护人员、项目开发人员和知识库管理员共同使用。上传人员应提供完整、清晰且能够提取正文的文件，管理员负责确认访问范围，检索结果应能定位到原文中的章节或页码。

第一章 文档提交与职责分工

内容维护人员负责检查文档标题、版本和正文是否一致，删除已失效的临时说明，并为每份文档填写简明的用途描述。文档修订后应提交完整的新版本，避免仅上传零散截图或缺少上下文的补充片段。同一知识库中的文件名称应便于识别，原始文件应按版本保留，以便后续核对。

知识库管理员负责为文档选择正确的知识库，核对成员访问范围，并关注解析和索引任务的结果。项目开发人员负责维护解析流程及失败提示。对于无法识别的格式，系统应明确返回原因，由上传人员转换为支持的格式后重新提交。

提交前的检查项目

1. 文件应包含可读的正文，标题和表格应与当前版本一致。
2. 单个上传文件不超过 50 MB，文件名称保留正确的扩展名。
3. 文字型 PDF 应可复制文本；扫描件需先完成 OCR。
4. 示例配置使用占位符，避免将真实密钥写入文档。

第二章 文档解析与索引处理

文档上传后先保存原始文件，再按扩展名选择对应的解析器。TXT 按整篇读取，PDF 按物理页提取，DOCX 和 Markdown 根据章节组织内容。解析结果需要保留正文、页码或节序号等定位信息，再交给后续流程切分与向量化；业务界面应明确展示当前处理状态。

支持的文件格式

文档类型	扩展名	提交要求
纯文本	TXT	使用 UTF-8，保留段落与换行
文字型 PDF	PDF	正文可复制，扫描件应先完成 OCR
Word 文档	DOCX	标题使用 Heading 样式，表格保留表头
Markdown	MD	保留标题层级，代码示例使用围栏

表格中的文档类型用于说明解析入口支持的格式。文件内容应与扩展名一致，不能通过修改后缀来完成格式转换。表格内的单元格正文应和相邻段落一起进入后续切分流程，确保检索到表格时仍能理解字段名称与具体数值的关系。

任务状态与失败处理

任务状态依次为 PENDING、PROCESSING、DONE；遇到读取失败、空内容或不支持的格式时，任务进入 FAILED 并记录可读的失败原因。修改源文件或修复外部依赖后，可以重新提交任务。成功结果应包含非空正文，避免将只有页码或空白符的内容当成有效知识。

Spring Boot 服务在解析完成后记录文件名、页数或节数以及耗时，便于追踪不同格式的处理结果。日志只记录定位信息，不打印完整的内部文档正文。

第三章 检索使用与日常维护

文档索引完成后，使用人员可以围绕具体业务问题发起检索。提问时应说明对象、版本或适用条件，例如询问某一版本的上传限制，而不是只输入宽泛的关键词。返回的回答应携带来源信息，便于读者回到原始文档检查上下文；缺少依据时，应提示补充问题或文档内容。

维护人员应定期核对知识库中的重复内容和过期说明。发现回答引用旧版制度时，先查看命中的文档版本、章节和任务状态，再判断是否需要重新索引。新版本生效后应按既定流程处理旧版本，使检索范围与当前使用的资料保持一致。

处理问题的基本步骤

1. 确认原始文件能够打开，并检查正文是否完整。
2. 检查解析结果，核对标题、段落、表格和页码。
3. 查看索引任务状态，按错误原因决定是否重试。
4. 使用文档中的固定关键词检索，核对命中来源。

常见问题示例

如果文字型 PDF 的正文为空，应检查文件是否实际由图片组成；如果 Word 表格未出现在结果中，应比较表格前后的段落顺序；如果 Markdown 代码块中的注释被识别为标题，应检查围栏是否闭合。定位问题时应保留能够复现问题的原始文件，并记录对应的页码或章节。

本制度的流程负责人是知识库管理员。对文档内容有疑问时，先联系文件维护人员核实；对解析结果有疑问时，提供文件名称和任务标识，便于开发人员检查同一份资料的处理过程。

POLICY-END